

INF01046 – Fundamentos de processamento de imagens

Aula 24 – Reconhecimento e Interpretação de Imagens

Horacio E. Fortunato

Instituto de Informática
Universidade Federal de Rio Grande do Sul
Porto Alegre – RS

hefortunato@inf.ufrgs.br

Link do curso: <http://www.inf.ufrgs.br/~hefortunato/cursos/INF01046>

2º semestre de 2009



Horacio E. Fortunato (UFRGS)

Processamento Digital de Imagens - Nesta disciplina

Sensores e Aquisição de imagens



- Sistema visual Humano
- Modalidade de Imagens
- Câmeras Digitais

Processamento para a interpretação humana



- Realce de Imagens:
 - Processamento de histograma
 - Filtragem espacial
 - Filtragem no domínio da frequência
- Restauração de Imagens:
 - Remoção de ruído
 - Remoção de borramento
- Espaços de Cores
- Imagens em Alta Faixa Dinâmica

Percepção por máquina



- Detecção de linhas e bordas
- Limiarização
- Segmentação

Armazenamento e Comunicação




- Compressão de imagens



Horacio E. Fortunato (UFRGS)

Reconhecimento e Interpretação de Imagens

A análise de imagens é um processo de descobrimento, de identificação e de entendimento de padrões que sejam relevantes à performance de uma tarefa baseada em imagens



Horacio E. Fortunato (UFRGS)

Reconhecimento e Interpretação de Imagens

- **Reconhecimento:** Classificação de objetos

- Métodos de reconhecimento:
 - Por decisão teórica (Dist. Mínima, Correlação, Classificadores Estatísticos ótimos (Bayessiano))
 - Estruturais (representação simbólica : cadeias e árvores)

- **Interpretação de imagens**

- Trata da atribuição de significado a um conjunto de elementos de imagens **reconhecidos**.



Horacio E. Fortunato (UFRGS)

Métodos de Reconhecimento de padrões

• Decisão teórica:

Classificação de objetos utilizando descritores quantitativos:

- Distância mínima
- Correlacionadores
- Classificadores Bayesianos
- Redes Neurais

• Estruturais :

Classificação de objetos utilizando descritores qualitativos ou estruturais (cadeias e árvores):

- Casamento de números de formas e cadeias
- Métodos sintáticos: Modelos que tratam os padrões simbólicos como sentenças de uma linguagem artificial



Horacio E. Fortunato (UFRGS)

Reconhecimento de padrões (Pattern recognition)

- Um **padrão** é:

- Uma **descrição quantitativa ou estrutural** de um objeto ou alguma outra entidade de interesse em uma imagem

- Um arranjo de **descritores**

- Uma **classe de padrões** é uma família de padrões que compartilham algumas propriedades comuns

- O **Reconhecimento de padrões** por máquina envolve técnicas para a atribuição dos padrões a suas respectivas classes



Horacio E. Fortunato (UFRGS)

Tipos de padrões

• Vetores (descritores quantitativos)

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

• Cadeias (descritores estruturais)

• Árvores (descritores estruturais)





FIGURE 12.5 A tree description of the image in Fig. 12.4.

Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.

Horacio E. Fortunato (UFRGS)

Padrões em forma vetorial - Exemplo

Três tipos de flores: Iris setosa, virginica e versicolor classificadas pela largura e comprimento de suas pétalas

FIGURE 12.1 Three types of iris flowers described by two measurements.

Padrão vetorial :
(comprimento, largura)

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$




Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.

Horacio E. Fortunato (UFRGS)

Padrões em forma vetorial - Exemplo

Assinatura de um objeto amostrada em n pontos

Padrão vetorial :

$$r = \begin{bmatrix} r(\theta_1) \\ r(\theta_2) \\ \vdots \\ r(\theta_n) \end{bmatrix}$$




FIGURE 12.2 A noisy object and its corresponding signature.

Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.

Horacio E. Fortunato (UFRGS)

Padrões em forma de cadeia - Exemplo

Estrutura em forma de escada, apropriada para ser descrita em forma de cadeia de símbolos $w = \dots ababab \dots$




FIGURE 12.3 (a) Staircase structure. (b) Structure coded in terms of the primitives a and b to yield the string description $\dots ababab \dots$

Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.

Horacio E. Fortunato (UFRGS)

Padrões em forma de árvore - Exemplo



FIGURE 12.4 Satellite image of a heavily built downtown area (Washington, D.C.) and surrounding residential areas (Courtesy of NASA).




FIGURE 12.5 A tree description of the image in Fig. 12.4.

Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.

Horacio E. Fortunato (UFRGS)

Métodos de decisão teórica

Métodos de decisão teórica baseiam-se na utilização de funções de decisão (ou discriminantes)

Padrão vetorial : $x = (x_1, x_2, \dots, x_n)$

M classes de padrões : w_1, w_2, \dots, w_M

M funções de decisão : $d_1(x), d_2(x), \dots, d_M(x)$

Se o padrão x pertence à i -ésima classe de padrões (w_i), então :

$$d_i(x) > d_j(x) \text{ para } j=1, 2, \dots, M; \quad j \neq i$$

A fronteira de decisão que separa as classes w_i e w_j é dada pelos valores de x para os quais $d_i(x) = d_j(x)$ ou : $d_i(x) - d_j(x) = 0$

Se $d_{ij}(x) = d_i(x) - d_j(x)$ então

$d_{ij}(x) > 0$ para padrões da classe w_i e
 $d_{ij}(x) < 0$ para padrões da classe w_j

Horacio E. Fortunato (UFRGS)

Casamento Classificador de distância mínima

- Para cada classe se define um 'vetor médio' ou 'protótipo' que representa à classe
- Para classificar um padrão seguem se os seguintes passos:
 - Calcular a distancia do padrão a cada 'protótipo'
 - Classificar o padrão como da classe com 'protótipo' mais próximo




Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.



Horacio E. Fortunato (UFRGS)

Casamento Classificador de distância mínima

- Como protótipo de cada classe pode utilizar-se o valor médio de um conjunto de amostras de padrões pertencentes a essa classe
- Como distancia pode utiliza-se a distância euclidiana
- Na prática o classificador de distância mínima funciona bem quando a distância entre as médias for grande em comparação com a dispersão ou aleatoriedade de cada classe em relação a sua média



Horacio E. Fortunato (UFRGS)

Casamento por Correlação

Quando estudamos convolução, definimos uma operação similar denominada 'correlação'

$$g(x, y) = f(x, y) \circ h(x, y) = \frac{1}{M \cdot N} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f^x(m, n) \cdot h(x+m, y+n)$$

O teorema da correlação é similar ao teorema da convolução:

$$f^x(x, y) \circ h^x(x, y) \Leftrightarrow F^x(u, v) \cdot H(u, v)$$

$$f^x(x, y) \cdot h^x(x, y) \Leftrightarrow F^x(u, v) \circ H(u, v)$$



Horacio E. Fortunato (UFRGS)

Correlação - Exemplo

Onde está a 'T'?

A correlação é máxima onde o padrão é localizado dentro da imagem.

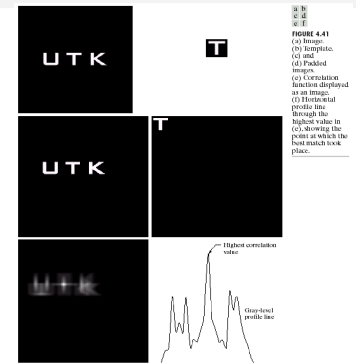


Imagem extraída do livro: Digital image processing 2ed, Gcnzales e woods.

Horacio E. Fortunato (UFRGS)

Correlação - Exemplo




Imagem extraída do livro: Digital image processing 2ed, Gonzales e woods.



Horacio E. Fortunato (UFRGS)

Casamento por Correlação

- O valor da correlação depende da intensidade do objeto na imagem e da intensidade do padrão

Para normalizar se define o coeficiente de correlação

$$\gamma(x, y) = \frac{1}{M \cdot N} \frac{\sum_{m=0}^{M-1} \sum_{n=0}^{N-1} [f(m, n) - \bar{f}(m, n)] \cdot [h(x+m, y+n) - \bar{h}]}{\left(\sum_{m=0}^{M-1} \sum_{n=0}^{N-1} [f(m, n) - \bar{f}(m, n)]^2 \cdot \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} [h(x+m, y+n) - \bar{h}]^2 \right)^{1/2}}$$

- A normalização para mudanças de escala e rotação pode ser difícil
- A correlação pode ser realizada no domínio da frequência



Horacio E. Fortunato (UFRGS)

Correlação - Exemplo

image




pattern



Classificadores estatísticos ótimos

- Abordagem probabilística
- Procura minimizar a probabilidade de erros de classificação

	Classe 1	Classe 2
Objeto tipo1	Classificação OK	Erro
Objeto tipo 2	Erro	Classificação OK



Classificadores estatísticos ótimos

A probabilidade que um padrão 'x' pertença a uma classe ' w_k ' é denotado por: $p(w_k/x)$

Se o classificador decidir que x pertence à classe ' w_i ' quando na realidade pertence à classe ' w_k ', então terá cometido uma 'perda' denotada por: L_{ki}

Se o padrão pode pertencer a uma das M classes, então a perda média ocorrida na atribuição de x à classe ' w_i ' é:

$$r_i(x) = \sum_{k=1}^M L_{ki} \cdot p(w_k/x)$$

Esta equação é chamada de 'Risco médio condicional'

Classificadores estatísticos ótimos

Da teoria de probabilidades, sabe-se que: $p(A/B) = \frac{p(A) \cdot p(B/A)}{p(B)}$

Então o 'Risco médio condicional' pode ser escrito na forma:

$$r_i(x) = \frac{1}{p(x)} \cdot \sum_{k=1}^M L_{ki} \cdot p(x/w_k) \cdot p(w_k)$$

Onde $p(x/w_k)$ é a função densidade de probabilidades dos padrões da classe w_k e $p(w_k)$ é a probabilidade total de ocorrência da classe w_k

O fator $1/p(x)$ pode ser eliminado sem alterar a ordem relativa dessas funções do menor para o maior valor. A equação para a perda média é então reduzida a

$$r_i(x) = \sum_{k=1}^M L_{ki} \cdot p(x/w_k) \cdot p(w_k)$$

Classificadores Bayesianos

Perda média

$$r_i(x) = \sum_{k=1}^M L_{ki} \cdot p(x/w_k) \cdot p(w_k) \quad i=1, 2, \dots, M$$

Se para cada padrão 'x' o classificador computa a perda média $r_i(x)$ para cada classe e atribui o padrão à classe com menor perda, a perda média total em relação a todas as decisões será mínima.

O classificador que minimiza a perda média total é chamado de **Classificador Bayesiano**

Classificadores Bayesianos

Para uma função de perda da forma 0 para sucesso e 1 para erro o classificador Bayesiano equivale a utilizar funções de decisão da forma:

$$d_j(x) = p(x/w_j) \cdot p(w_j) \quad j=1, 2, \dots, M$$

Onde:

- $p(x/w_k)$ é a função densidade de probabilidades dos padrões da classe w_k
- $p(w_k)$ é a probabilidade total de ocorrência da classe w_k

Classificadores Bayesianos





FIGURE 12.11
Two simple pattern classes and their Bayes decision boundary (shown shaded).

Classificadores Bayesianos

FIGURE 12.12
Formation of a pattern vector from registered pixels of four digital images generated by a multispectral scanner.



Classificadores Bayesianos Exemplo


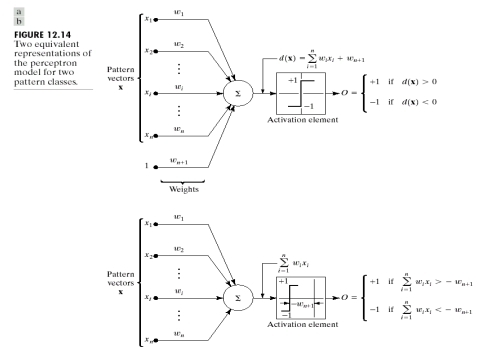


FIGURE 12.13 (a) Multispectral image. (b) Printout of machine classification results using a Bayes classifier. (Courtesy of the Laboratory for Applications of Remote Sensing, Purdue University)

Redes neurais



Redes neurais




FIGURE 12.15
(a) Patterns belonging to two classes. (b) Decision boundary determined by training.

Redes neurais

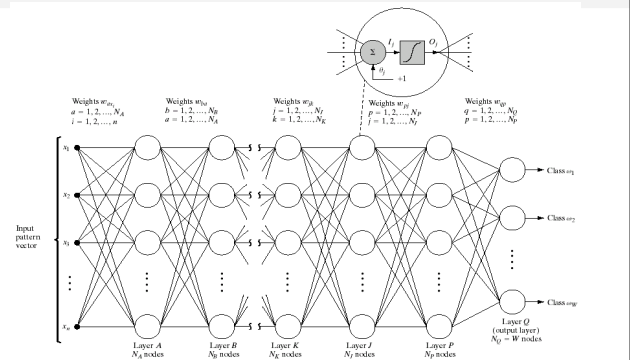



FIGURE 12.16 Multilayer feedforward neural network model. The blowup shows the basic structure of each neuron element throughout the network. The offset, θ_j , is treated as just another weight.

Redes neurais Exemplo

FIGURE 12.18
(a) Reference shapes and (b) typical noisy shapes used in training the neural network of Fig. 12.19. (Courtesy of Dr. Lalit Gupta, ECE Department, Southern Illinois University.)



Redes neurais Exemplo




FIGURE 12.19
Three-layer neural network used to recognize the shapes in Fig. 12.18. (Courtesy of Dr. Lalit Gupta, ECE Department, Southern Illinois University.)


Redes neurais Fronteiras de decisão

Network structure	Type of decision region	Solution to exclusive-OR problem	Classes with meshed regions	Most general decision surface shapes
Single layer	Single hyperplane			
Two layers	Open or closed convex regions			
Three layers	Arbitrary (complexity limited by the number of nodes)			

FIGURE 12.23
Types of decision regions that can be formed by single- and multilayer feed-forward networks with one and two layers of hidden units and two inputs. (Lippman)

Métodos estruturais Grafos

- A classificação utilizando grafos para descrever objetos pode ser computacionalmente complexa



Métodos sintático

- Uma gramática define um conjunto de regras para construir cadeias de primitivas
- Diferentes gramáticas definem diferentes famílias ou classes de objetos
- Os objetos são classificados pela gramática (em qual linguagem o padrão representa uma sequência válida)




FIGURE 12.26
(a) Object represented by its (pruned) skeleton. (b) Primitives. (c) Structure generated by using a regular string grammar.

Métodos sintáticos

Definimos uma gramática como uma tupla de 4:

$$G = (N, \Sigma, P, S)$$

Em que:

- N = um conjunto finito de variáveis chamados de não-terminais
- Σ = um conjunto finito de constantes chamadas terminais
- P = um conjunto de regras de reescrita chamadas produções
- S = O símbolo inicial (pertence a N)

Métodos sintáticos Exemplo

Gramática para construir números binários (seqüências de 1 e 0):

$G = (N, \Sigma, P, S)$

$N = \{ S, A, B \}$ (variáveis), $\Sigma = \{ 0, 1 \}$, (primitivas) $S = \{ S \}$ (inicial)

P = regras:

- 1) - $S \rightarrow A$
- 2) - $A \rightarrow 1A$
- 3) - $A \rightarrow 0A$
- 4) - $A \rightarrow B$
- 5) - $B \rightarrow 1$
- 6) - $B \rightarrow 0$

Sequencia de regras para construir a cadeia 110: (em ordem reverso)

- 6) $110 \rightarrow 11B$: 0 zero final vem de reeemplazar B por 0 (regra 6)
- 4) $11B \rightarrow 11A$: o B final vem de reemplazar A por B (regra 4)
- 2) $11A \rightarrow 1A$: a seq. 1A final vem de aplicar a regra 2
- 2) $1A \rightarrow A$: a seq. 1A final vem de aplicar a regra 2
- 1) $A \rightarrow S$: a A vem de aplicar a regra 1 a S



Processamento Digital de Imagens - Tarefas

Tarefas Novas:

- Leia o Capítulo 12 (aula 24) do livro Gonzalez, R. & Woods 2da Ed. (em Inglês)
- Faça os exercícios do Capítulo 12 (aula 24) do livro Gonzalez, R. & Woods 2da Ed. (em Inglês)

Nota Importante: No livro Gonzalez, R. & Woods em português os capítulos possuem número diferente

Livro Gonzalez, R. & Woods 2ª Ed. (em Inglês):

Gonzalez, R. & Woods, R. Digital Image Processing 2ª Ed. Prentice Hall, 2002.

Link do curso: <http://www.inf.ufrgs.br/~hefortunato/cursos/INF01046>

