

Inteligência Artificial

Sistemas Especialistas Tratamento de Incertezas

Prof. Paulo Martins Engel

Conceitos de Incerteza

- A incerteza pode ser considerada como a falta de informação adequada para tomar uma decisão.
- Lidar com incertezas é uma importante capacidade dos especialistas humanos.
- **Conhecimento incerto**: freqüentemente o perito possui somente conhecimento heurístico sobre alguns aspectos do domínio.
Ex: ele sabe que um certo conjunto de fatos *provavelmente* leva a uma certa conclusão.
- **Dado incerto**: mesmo quando se está seguro do conhecimento sobre certo aspecto do domínio, pode haver *incerteza nos dados* que descrevem o ambiente externo.
Ex.: tentando inferir a causa de um fenômeno observado, pode-se depender de resultados *questionáveis* de testes.
- **Informação incompleta**: freqüentemente é necessário tomar decisões com base em *informação incompleta*.
Ex.: o médico pode ter que iniciar o tratamento de um paciente *antes* mesmo de ter *todos* os resultados dos exames de laboratório que ele gostaria.

2

Exemplo: conhecimento incerto

- O problema de o pedal do freio estar baixo ou ir todo ao fundo tem como (*algumas*) causas possíveis:
 1. As lonas do freio estão gastas (FC = 0,8)
 2. O nível do líquido de freio está baixo (FC = 0,6)
 3. O cilindro está defeituoso (FC = 0,5)
- A incerteza neste caso é tipicamente tratada por uma abordagem numérica, baseada em probabilidades, quer na forma subjetiva, quer na forma tradicional (baseada em experimentos de freqüência).
- Obs.: o pedal pode estar baixo porque a mola quebrou!
- Regra *causal* consistente: (pouco útil para diagnóstico)
se
as lonas do freio estão gastas ou
o nível do líquido de freio está baixo
ou o cilindro está defeituoso
então
o pedal do freio está baixo
- Regra *heurística* (não é consistente): (útil para diagnóstico)
se
o pedal do freio está baixo
então
as lonas do freio estão gastas ou
o nível do líquido de freio está baixo
ou o cilindro está defeituoso

3

Raciocínio abduativo

- Normalmente as regras úteis são de natureza heurística, *inconsistentes*:
se
o motor não pega e
as luzes não acendem
então
o problema é bateria ou cabo
- Seria possível, apesar de improvável, que a bateria ou os cabos estivessem em ordem, mas que o carro simplesmente tivesse o motor de partida com problemas e os faróis queimados.
- Raciocínio abduativo: A partir de **P** → **Q** e **Q** é possível inferir **P**.
- A abdução é uma regra inconsistente, a conclusão não é necessariamente verdadeira quando as premissas são verdadeiras.
- As regras heurísticas podem expressar uma política explícita para a crença.
- P. ex., a regra **P** → **Q** (0,9) expressa a crença: “se você acredita que **P** seja verdadeiro, então você acredita que **Q** irá ocorrer em 90% dos casos.

4

Dados incertos

- Pode-se usar medidas de certeza para refletir a nossa crença na *qualidade* dos dados.
- No exemplo anterior, a proposição: **as luzes acendem (0,2)** pode indicar o resultado da verificação da intensidade com que acendem os faróis: acendem, mas são fracos e pouco visíveis.
- Crenças e dados imperfeitos podem ser propagados através das regras a fim de gerar conclusões.
- Os formalismos baseados em lógica podem ser estendidos para tratar *abdução*.
- O raciocínio não-monotônico aborda o problema de crenças que podem ser modificadas.
- Ele trata a incerteza fazendo as suposições mais razoáveis com base na informação incerta, procedendo como se estas informações fossem verdadeiras.
- Se mais tarde a crença mudar, é necessário reexaminar as conclusões derivadas daquela crença.
- Os *algoritmos de manutenção da verdade* são empregados para manter a base de conhecimento consistente.

5

Raciocínio não-monotônico

- O raciocínio convencional (lógica de predicados) é baseado em três suposições:
- *Os predicados devem ser suficientes em relação ao domínio de aplicação:*
Toda informação necessária para resolver o problema deve ser representada.
- *A base de informação deve ser consistente:*
As porções de conhecimento não se contradizem.
- *Através do uso de regras de inferência, a informação conhecida cresce monotonamente.*
- Se qualquer destas suposições não for satisfeita, a abordagem baseada em lógica convencional não funcionará.
- Sistemas não-monotônicos lidam com estas questões.
- Questão importante sobre escassez de conhecimento: como tratar a falta de conhecimento sobre um predicado p ?
- A falta de conhecimento significa que *não temos certeza que p é verdadeiro* ou significa que *temos certeza que p não é verdadeiro*?
- PROLOG usa *hipótese de mundo fechado*:

Tudo que não pode ser provado verdadeiro é falso!

6

Raciocínio não-monotônico

- Uma abordagem para a falta de conhecimento é fazer suposições explícitas sobre a verdade.
- Raciocina-se com base como o mundo normalmente funciona:
- A maioria dos pássaros voa.
- A lógica pode ser estendida por *operadores modais*: **a_menos_que**

$p(x)$ **a_menos_que** $q(x) \rightarrow r(x)$

Podemos inferir $r(x)$ se $p(x)$ for verdadeiro e não acreditamos que $q(x)$ seja verdadeiro,

Se, mais tarde, constatamos que $q(x)$ é verdadeiro, então $r(x)$ deve ser *retratado*.

- O operador modal **a_menos_que** trata da *crença* em vez da verdade: “ou desconhecido ou presumidamente falso”.

7

Problemas Gerais

- Suponha que x é A com grau de confiança x_1 e que a Base de Conhecimento contenha a regra:
- R_1 : Se x é A Então y é B ($FC = r_1$)
 1. Como extrair do especialista valores consistentes para r_1 ?
 2. Como computar ou obter de outro modo o valor de x_1 ?
 3. Como r_1 e x_1 devem ser representados: um escalar, um intervalo, uma expressão linguística, uma distribuição,...
 4. No caso mais geral, quando a premissa é composta por múltiplas cláusulas, como agregar o grau de certeza total da premissa?
 5. Como definir a função que agrega os graus de certeza da premissa com o da regra?
 6. Se múltiplas regras determinam a mesma conclusão, qual a função que determina o grau de certeza final da conclusão?

8

Raciocínio baseado em Probabilidades Condicionais

- A inferência probabilística usa a informação disponível sobre os valores de algumas variáveis para obter a probabilidade para valores de outras variáveis.
- A probabilidade condicional $P(B|A)$ é a probabilidade de **B** ocorrer dado que **A** tenha ocorrido. Ela é calculada a partir da probabilidade conjunta $P(A,B)$:

$$P(B|A) = \frac{P(A,B)}{P(A)}$$

- Esta probabilidade pode ser interpretada como um *fator de confiança* que se pode inferir a partir dos dados na regra: $P(A) \rightarrow P(B)$
- $P(A)$ e $P(B)$ são as *probabilidades marginais* de **A** e **B**, respectivamente. Elas são também chamadas de probabilidades a priori destes valores de variáveis.


9

O Teorema de Bayes

- O Teorema de Bayes mostra uma maneira de se calcular a probabilidade de um evento em particular, a partir de um conjunto de observações.
- O evento pode ser um determinado valor de um atributo especial, que seria o rótulo de uma classe i , ou hipótese H_i .
- Inicialmente, se determina a probabilidade a priori de cada hipótese H_k , $P(H_k)$ presente no domínio. ($H_1, H_2, \dots, H_i, \dots, H_n$)
- A seguir, a partir de conjuntos de amostras contendo objetos pertencentes a cada uma das hipóteses possíveis, se determinam as probabilidades com que ocorrem os atributos observáveis ($E_1, E_2, \dots, E_j, \dots, E_l$), as $P(E_j|H_k)$.
- O TB afirma que, para um objeto do domínio no qual ocorra p. ex. E_j , a probabilidade de que este objeto satisfaça a hipótese H_i é dada por $P(H_i|E_j)$:

$$P(H_i|E_j) = \frac{P(E_j|H_i) \cdot P(H_i)}{\sum_{k=1}^n P(E_j|H_k) \cdot P(H_k)}$$

10



- Determinar pelo Teorema de Bayes, a probabilidade de um objeto que tenha dois furos ser azul, $P(A|D)$.

$$P(A|D) = \frac{P(D|A)P(A)}{P(D|A)P(A) + P(D|V)P(V)}$$

Probabilidades a priori, $P(A)$ e $P(V)$:

$$P(A) = 0,5 \quad P(V) = 0,5$$

Verossimilhanças (em relação a D) das classes (A e V), $P(D|A)$ e $P(D|V)$:

$$P(D|A) = 4/6 = 0,667 \quad P(D|V) = 2/6 = 0,333$$

$$P(A|D) = \frac{0,667 \times 0,5}{0,667 \times 0,5 + 0,333 \times 0,5} = 0,667$$

11

Exemplo de SE com raciocínio probabilístico

- O PROSPECTOR é um exemplo de SE que utiliza raciocínio probabilístico para localizar depósitos de minérios:
- Sabe-se a probabilidade a priori de se encontrar cada minério.
- Sabe-se a probabilidade de que se existir um certo minério, determinadas características físicas serão encontradas (verossimilhança).
- Então, utiliza-se o TB para calcular a probabilidade de que os vários minérios estejam presentes, a partir das evidências (dados) que foram coletados.

12

Dificuldades com o método de Bayes

- O uso do TB pode depender de um número grande de variáveis.
- Em medicina, pode-se usar o TB para determinar a probabilidade de uma doença específica dado um conjunto de sintomas.
- Deve-se estimar a probabilidade a priori de um paciente ter uma determinada doença.
- Deve-se estimar a probabilidade condicional dos diversos sintomas em cada (todas!) doença.
- É normalmente impossível obter valores consistentes e completos para todas estas probabilidades para a população em geral.
- Como $P(H) + P(\neg H) = 1 \therefore P(H) = 1 - P(\neg H)$
- Similarmente, $P(H|E) = 1 - P(\neg H|E)$
- Os médicos que trabalharam no MYCIN eram extremamente relutantes em formular seu conhecimento nesta forma.

13

Fatores de Certeza (FC)

- Um FC é um valor numérico que expressa quanto se acredita que, com base num conjunto de evidências, pode-se aceitar uma dada conclusão.
- O FC pode variar de 1 (crença total) a -1 (descrença total).
- O FC é uma quantificação subjetiva baseada no julgamento e intuição do perito.
- Exemplo: regra para diagnosticar problema numa lâmpada de cabeceira:

SE

a lâmpada de cabeceira está ligada na tomada e
a tomada tem corrente e
o interruptor está ligado
(e a lâmpada não acende)

ENTÃO

há uma evidência sugestiva (0,8) que a lâmpada esteja queimada.

14

Medidas de Crença

- O fator de certeza depende de medidas de crença e descrença:

$$FC(H,E) = MC(H, E) - MD(H, E)$$

$FC(H, E)$ é o *fator de certeza* na hipótese H baseado na evidência E

$MC(H, E)$ é a *medida de crença* em H baseado na evidência E.

$MD(H, E)$ é a *medida de descrença* em H baseado em E.

- Por definição, $0 \leq MC \leq 1$; $0 \leq MD \leq 1$.
- Num sistema que usa fatores de certeza, as regras devem ser estruturadas de forma que cada regra ou aumenta a crença numa determinada conclusão, ou aumenta a descrença na conclusão.

15

Medidas de Crença e Probabilidades

- As medidas de crença e descrença estão relacionadas com probabilidades:

$$MC(H,E) = \begin{cases} 1 & \text{Se } P(H) = 1 \\ \frac{\max[P(H|E), P(H)] - P(H)}{\max[1,0] - P(H)} & \text{Caso contrário} \end{cases}$$

$$MD(H,E) = \begin{cases} 1 & \text{Se } P(H) = 0 \\ \frac{\min[P(H|E), P(H)] - P(H)}{\min[1,0] - P(H)} & \text{Caso contrário} \end{cases}$$

- Note que ou $MC = 0$ ou $MD = 0$.
- $FC(H,E) = MC(H, E) - MD(H, E)$
- Se FC for positivo, o sistema acredita que a hipótese é verdadeira; se for negativo, o sistema acredita que a hipótese é falsa.

16

Combinando Fatores de Certeza

- Combinando várias regras sobre a **mesma hipótese** (*conclusão*):
As medidas de crença e descrença de uma hipótese dadas duas regras R_1 e R_2 são calculadas pela seguinte combinação de medidas individuais:

$$MC(H, R_1 \wedge R_2) = \begin{cases} 0 & \text{Se } MD(H, R_1 \wedge R_2) = 1 \\ MC(H, R_1) + MC(H, R_2) \cdot (1 - MC(H, R_1)) & \text{Caso contrário} \end{cases}$$

$$MD(H, R_1 \wedge R_2) = \begin{cases} 0 & \text{Se } MC(H, R_1 \wedge R_2) = 1 \\ MD(H, R_1) + MD(H, R_2) \cdot (1 - MD(H, R_1)) & \text{Caso contrário} \end{cases}$$

Pode ser visto como a parcela que ainda não temos certeza, ou que R_1 não garante

17

- Dadas 4 regras que sugerem a conclusão C , ache o FC acumulado para C :

Regra	FC
R_1	0,8
R_2	0,3
R_3	-0,2
R_4	0,7

Para a regra R_1 : $MC = 0,8$ e $MD = 0$.

Considerando a regra R_2 : $MC = 0,8 + 0,3 (1 - 0,8) = 0,86$

$$MD = 0 + 0 (1 - 0) = 0$$

Considerando a regra R_3 : $MC = 0,86 + 0 (1 - 0,86) = 0,86$

$$MD = 0 + 0,2 (1 - 0) = 0,2$$

Considerando a regra R_4 : $MC = 0,86 + 0,7 (1 - 0,86) = 0,958$

$$MD = 0,2 + 0 (1 - 0,2) = 0,2$$

$$FC_{acum} = 0,958 - 0,2 = 0,758.$$

18

Conjunção de conclusões

$$MC(C_1 \wedge C_2, e) = \min[MC(C_1, e), MC(C_2, e)]$$

$$MD(C_1 \wedge C_2, e) = \min[MD(C_1, e), MD(C_2, e)]$$

onde C_1 é a conclusão 1, C_2 é a conclusão 2, e é a evidência disponível

Disjunção de conclusões

$$MC(C_1 \vee C_2, e) = \max[MC(C_1, e), MC(C_2, e)]$$

$$MD(C_1 \vee C_2, e) = \max[MD(C_1, e), MD(C_2, e)]$$

19

Exemplo de conjunção/disjunção de conclusões

Dadas as seguintes conclusões de um diagnóstico de um problema num carro:

C_1 : o problema exige imediata atenção (0,8)

C_2 : há um problema no sistema elétrico (0,6)

C_3 : há um curto-circuito no sistema elétrico (0,4)

C_4 : há um problema no distribuidor (0,2)

- Encontre o FC de que há um problema no sistema elétrico (e) que exige imediata atenção **e** o problema é um curto-circuito **ou** um problema no distribuidor

$$MC(C_1 \wedge C_2) = \min[0,6, 0,8] = 0,6$$

$$MC(C_3 \vee C_4) = \max[0,4, 0,2] = 0,4$$

$$MC(C_1 \wedge C_2 \wedge (C_3 \vee C_4)) = \min[0,6, 0,4] = 0,4$$

20