

Inteligência Artificial

Redes Neurais Competitivas Mapas Auto-organizáveis

Prof. Paulo Martins Engel

Sistemas Auto-organizáveis

- Os sistemas auto-organizáveis estão relacionados com aprendizagem não-supervisionada.
- O objetivo de um algoritmo de aprendizagem não-supervisionada é extrair características significativas dos dados de entrada, sem supervisão externa.
- O algoritmo procura encontrar, de forma autônoma, *similaridades* entre conjuntos de dados, identificando assim, *agrupamentos* de dados com características comuns.
- Nos sistemas neurais auto-organizáveis, os *pesos* dos neurônios armazenam as características de um protótipo correspondente a um agrupamento de dados de entrada com características similares.
- O algoritmo de treinamento aplica regras locais de modificação de pesos, ou seja, levando em conta uma *vizinhança* em torno do neurônio.
- A estrutura de um sistema auto-organizável pode consistir em apenas uma camada de entrada e uma camada auto-organizável de saída, ou em múltiplas camadas, em que a auto-organização se processa sequencialmente através das camadas.

2

Modelos Descritivos

- A tarefa de geração de um modelo descritivo consiste (em grande parte) em analisar os dados do domínio (*entradas*) e sugerir uma *partição* do domínio, de acordo com *similaridades* observadas nos dados.



- Determinação de uma configuração de centróides de agrupamentos dos dados
- Modelo de agrupamento dos dados

3

Identificação de agrupamentos

- A identificação de agrupamentos é uma tarefa descritiva que procura agrupar dados utilizando a similaridade dos valores de seus atributos como fator de decisão quanto à sua pertinência num entre vários agrupamentos possíveis.
- Este processo utiliza técnicas de aprendizagem não-supervisionada, pois a similaridade entre os atributos é uma característica intrínseca dos dados, não necessitando de um arquivo de treinamento com classes pré-definidas.
- Em geral, a identificação dos agrupamentos intrínsecos dos dados permite a descrição de cada agrupamento através de um padrão protótipo.
- O processo normalmente é iterativo e interativo, necessitando que o usuário modifique parâmetros e rerepresente os dados até encontrar uma configuração satisfatória de agrupamentos.
- A ênfase nesta tarefa é a *descrição* dos dados e não a previsão de como um novo caso será classificado.

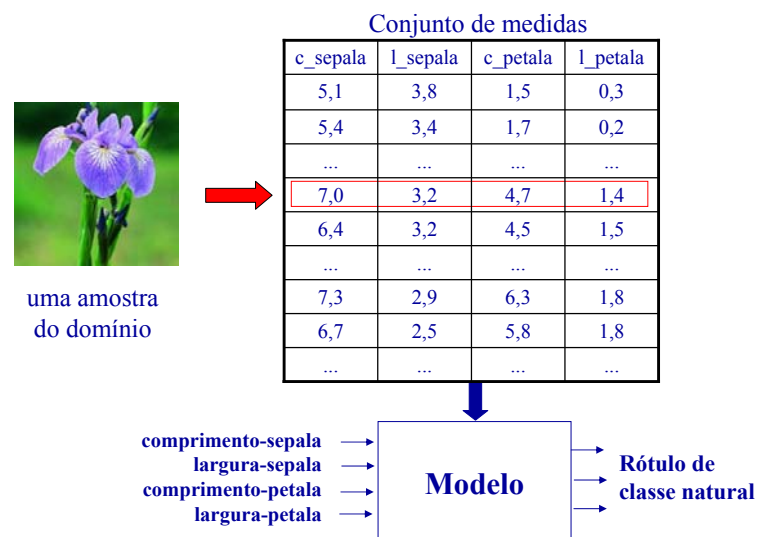
4

Avaliação de modelos descritivos

- Questão fundamental: quantos grupos representam mais adequadamente os dados?
- Usualmente, adotam-se métricas estatísticas de qualidade da configuração de agrupamento: média de distâncias intra-grupo e de distâncias inter-grupos.
- A avaliação da qualidade de um modelo descritivo normalmente é problemática se não dispusermos de informação extra (*conhecimento de perícia*).
- A *busca informada* pela melhor configuração é muito mais eficiente.

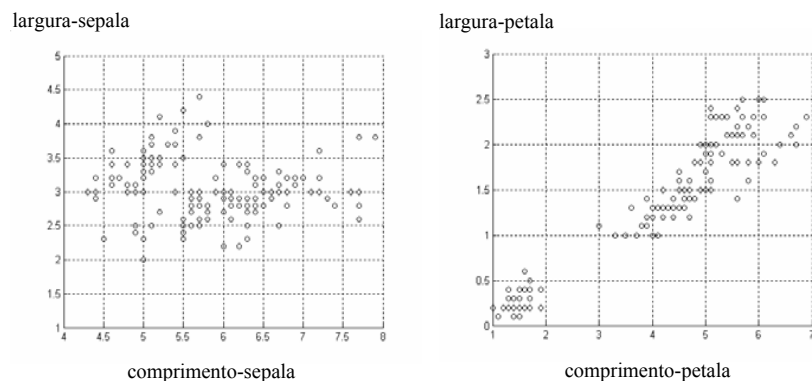
5

Dados para agrupamento de subespécies da planta Iris



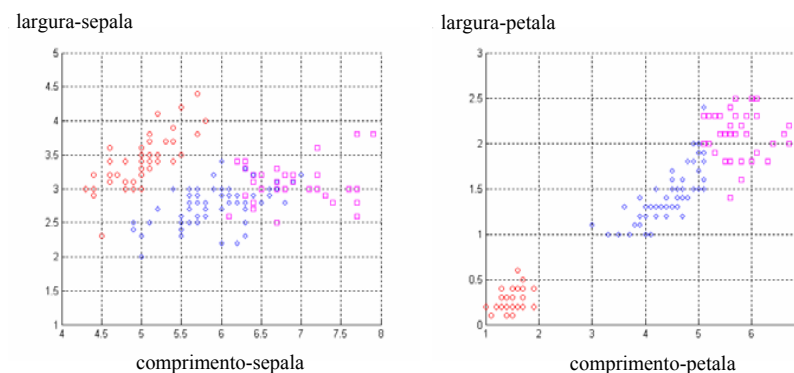
6

Dados da planta Iris



7

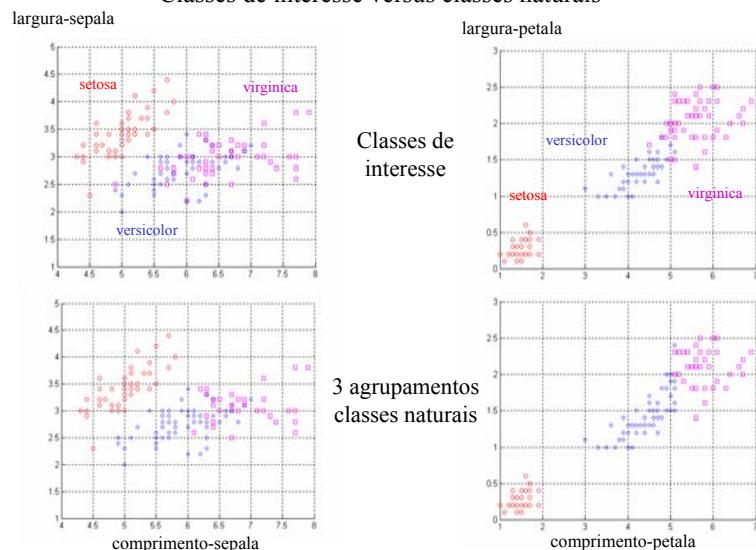
Modelo de agrupamento para os dados da planta Iris



8

Modelo de agrupamento para os dados da planta Iris

Classes de interesse versus classes naturais



9

Modelos de RN para descoberta de agrupamentos


- Existe uma variedade de modelos de RN que são usados para a tarefa de descoberta de agrupamentos. Todos eles têm em comum algum processo de aprendizagem não supervisionada, auto-organizável.
- Nas *redes competitivas*, um protótipo de um agrupamento é armazenado como pesos de um neurônio.
- O Mapa Auto-Organizável (*SOM, self-organizing map*), proposto por T. Kohonen (1982), é uma rede competitiva organizada numa grade bidimensional (ou de outra dimensionalidade) onde existe interação entre neurônios dentro de uma vizinhança.
- Por causa desta característica, a rede SOM além de armazenar os protótipos dos agrupamentos, preserva também a topologia original da distribuição dos agrupamentos no espaço de características.

10

Aprendizado do protótipo de um agrupamento

- Um neurônio com aprendizado competitivo pode aprender o protótipo de um agrupamento de vetores de entrada, segundo o procedimento a seguir:
 1. Selecionar um vetor de entrada \mathbf{x}_i , ao acaso, de acordo com a distribuição de probabilidade do agrupamento.
 2. Atualizar os pesos por $\mathbf{w}(n+1) = \mathbf{w}(n) + \alpha (\mathbf{x}(n) - \mathbf{w}(n))$
 3. Repetir os passos 1 e 2 para um número de vezes igual ao número de vetores de entrada do agrupamento.
 4. Repetir o passo 3 várias vezes.
- Com isso, \mathbf{w} se modifica em direção à média dos vetores do agrupamento:


$$\text{Se } \langle \Delta \mathbf{w} \rangle = 0 \text{ então } \langle \mathbf{w} \rangle = \langle \mathbf{x} \rangle$$
- Deve-se reduzir α com o tempo, pois uma vez que \mathbf{w} atingiu a média do agrupamento, ele não deve mais se modificar.



11

Exemplo de RNC

- A RNC abaixo é formada por uma camada competitiva com três neurônios compatitivos (*instars*). A camada de entrada apenas distribui o vetor bidimensional de sinais de entrada normalizados.
- A cada apresentação de um vetor de entrada, apenas um instar (o vencedor de índice k) terá saída $y_k = 1$. Todos os demais terão saída nula.



12



O Mapa Auto-Organizável (SOM)

- Sistema auto-organizável inspirado no córtex cerebral.
- Nos mapas tonotópicos do córtex, p. ex., neurônios vizinhos respondem a frequências sonoras similares. Existe correlação entre a ordenação da frequência de entrada e a posição do neurônio no mapa.
- A arquitetura do SOM corresponde à uma rede neural com uma camada competitiva bidimensional ou unidimensional, onde existe *interação lateral* entre os neurônios dentro de uma *vizinhança*.
- Os neurônios competem entre si, através de conexões especiais que implementam *reforço central e inibição lateral*.
- Através do ajuste de pesos considerando as vizinhanças, se preserva a distribuição de probabilidades (*topologia*) dos vetores de entrada.
- Com isso, unidades fisicamente próximas no mapa respondem a classes de vetores de entrada que são próximas entre si.
- Regiões no espaço de entrada com maior densidade de vetores de entrada produzem regiões no mapa envolvendo maior número de neurônios.

13

Somatotopia: mapeamento das sensações da superfície do corpo na estrutura do cérebro
Existem outros mapas sensoriais: retinotopia, tonotopia


Córtex Somatossensorial primário



Áreas Somatossensoriais

14

Arquitetura da rede SOM



15

Processamento do SOM

- A rede SOM pode ser modelada de forma contínua, através de um sistema dinâmico, envolvendo conexões realimentadoras para produzir excitação central e inibição lateral, ou de forma discreta, envolvendo um juiz externo, para escolher um neurônio vencedor num processo de competição do tipo “o vencedor leva tudo”.
- O processamento da SOM pode ser resumido através do seguinte procedimento de aprendizado não-supervisionado:
 - Apresentar um vetor na entrada da rede
 - Calcular as ativações dos neurônios da camada competitiva
 - Determinar o neurônio vencedor (neurônio mais próximo da entrada)
 - **Fase de treinamento:**
 - Modificar o vetor de pesos do vencedor e de todos os neurônios dentro de uma vizinhança do vencedor.
 - **Fase de recuperação (recordação) ou atuação:**
 - O neurônio vencedor indica o agrupamento ao qual o vetor de entrada pertence.

16

Atualização dos pesos para vizinhança contínua

Todos neurônios da rede têm seus pesos atualizados por:


$$\rightarrow w_i(n+1) = w_i(n) + \eta(n) \cdot \pi_{ic}(n) \cdot (x(n) - w_i(n))$$

Sendo π_{ic} a função de vizinhança gaussiana, centrada no neurônio vencedor de índice "c":

$$\rightarrow \pi_{ic}(n) = \exp\left(-\frac{d_{ic}^2}{2\sigma^2(n)}\right)$$

A largura da vizinhança deve também decrescer com o tempo:

$$\rightarrow \sigma(n) = \sigma_0 \exp\left(-\frac{n}{\tau_2}\right)$$




Tipicamente, escolhe-se σ_0 de modo que toda a rede sofra ajustes significativos na fase inicial do aprendizado.

17

Simulação da rede SOM

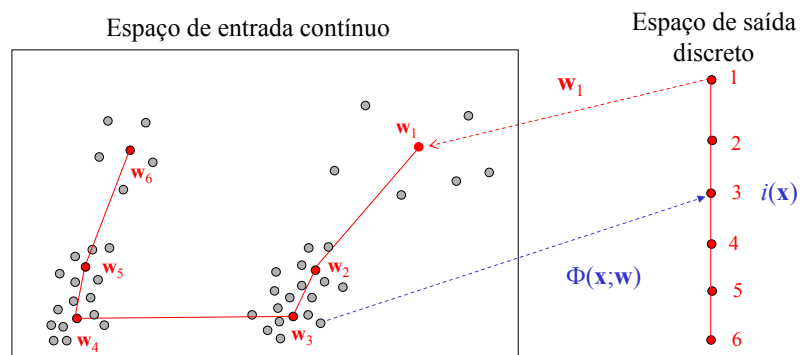
- Inicialização aleatória dos pesos normalizados
- A auto-organização da rede pode ser a qualquer tempo visualizada traçando-se linhas no espaço dos pesos entre os vetores de peso que são os vizinhos mais próximos.
- Para melhor visualização, apenas as linhas ortogonais entre vizinhos são traçadas.
- Com a inicialização aleatória normalizada, a rede não está auto-organizada e a figura correspondente é de uma malha de conexões aleatórias de pontos numa circunferência.
- Conforme o treinamento avança, a rede vai se tornando auto-organizada com as conexões entre pesos de neurônios vizinhos correspondendo à distribuição dos vetores de entrada.



18

Mapeamento do Espaço de Entrada


- A organização do mapa é visualizada pela imagem dos pesos no espaço de característica, assinalando os vizinhos mais próximos.



19



Rede SOM treinada

- Entradas: os quatro vetores de um espaço de Hamming bidimensional



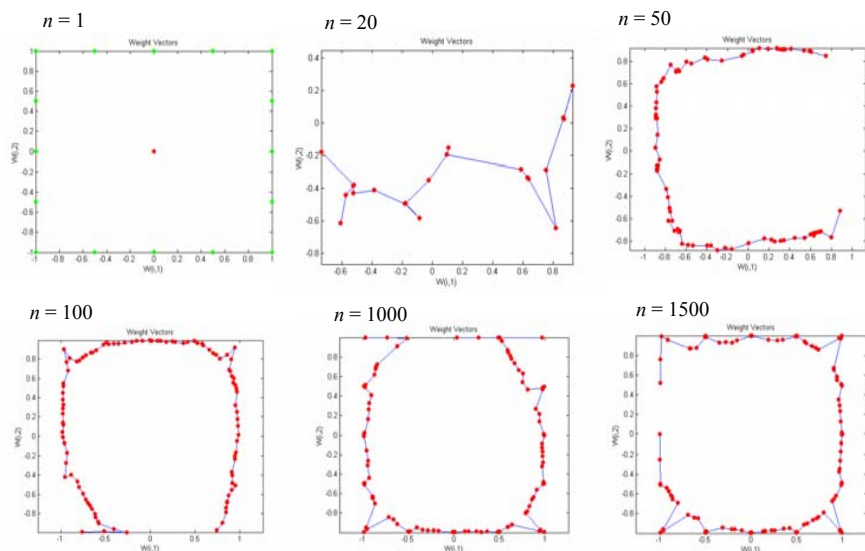
Distribuição triangular na entrada:

Distribuição circular na entrada:



20

SOM unidimensional



21

Simulação do SOM

- A simulação discreta do SOM é composta das seguintes etapas:
 1. Inicializar os pesos da rede aleatoriamente e os parâmetros η , σ e n_{max} .
Inicializar a variável de tempo discreto $n = 1$.
 2. Apresentar, aleatoriamente, um vetor de entrada do arquivo de treinamento e calcular a ativação de todos os neurônios da rede.
 3. Determinar o neurônio vencedor, de índice c .
 4. Calcular o fator de vizinhança (π_{ic}) para cada neurônio i da rede, em função da sua distância em relação ao neurônio c , d_{ic} .
 5. Atualizar os pesos de todos os neurônios da rede, levando em conta o seu fator de vizinhança.
 6. Incrementar n e atualizar os parâmetros η e σ .
 7. Voltar para 2 enquanto $n \leq n_{max}$.

22

Entradas: nomes de animais e seus atributos

	pombo	galinha	pato	ganso	cojuja	falcão	águia	raposa	cão	lobo	gato	tigre	leão	cavalo	zebra	vaca
é pequeno	1	1	1	1	1	1	0	0	0	0	1	0	0	0	0	0
é médio	0	0	0	0	0	0	1	1	1	1	0	0	0	0	0	0
é grande	0	0	0	0	0	0	0	0	0	0	0	1	1	1	1	1
tem 2 patas	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0
tem 4 patas	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1
tem pelos	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1
tem cascos	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	1
tem crina	0	0	0	0	0	0	0	0	0	1	0	0	1	1	1	0
tem penas	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0
caça	0	0	0	0	1	1	1	1	0	1	1	1	1	0	0	0
corre	0	0	0	0	0	0	0	0	1	1	0	1	1	1	1	0
voa	1	0	0	1	1	1	1	0	0	0	0	0	0	0	0	0
nada	0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0

23

Visualização por rotulação

- Podemos visualizar um mapa de características rotulando cada neurônio pelo padrão de teste que excita este neurônio de maneira máxima (*melhor estímulo*).
- A rotulação produz uma partição da grade de neurônios (10 x 10) evidenciando uma hierarquia de domínios aninhados.

pato	pato	cavalo	cavalo	zebra	zebra	vaca	vaca	vaca	vaca
pato	pato	cavalo	zebra	zebra	zebra	vaca	vaca	tigre	tigre
ganso	ganso	ganso	zebra	zebra	zebra	lobo	lobo	tigre	tigre
ganso	ganso	falcão	falcão	falcão	falcão	lobo	lobo	tigre	tigre
ganso	coruja	falcão	falcão	falcão	falcão	lobo	lobo	leão	leão
pombo	coruja	coruja	falcão	falcão	falcão	cão	cão	leão	leão
pombo	pombo	coruja	coruja	coruja	coruja	cão	cão	cão	leão
pombo	pombo	águia	águia	águia	águia	cão	cão	cão	gato
galinha	galinha	águia	águia	águia	águia	raposa	raposa	raposa	gato
galinha	galinha	águia	águia	águia	águia	raposa	raposa	raposa	gato

24